

图像处理实验报告

210810508-彭珂

May 19, 2024

Contents

1	CV 模型	1
1.1	模型介绍	1
1.2	数学原理	2
1.3	代码实现	3
1.4	实验结果	7
1.5	结论与讨论	9
2	RSF 模型	10
2.1	模型介绍	10
2.2	数学原理	10
2.3	代码实现	12
2.4	实验结果	17
2.5	结论与讨论	20

1 CV 模型

1.1 模型介绍

CV 模型是一个非常著名的基于区域的活动轮廓模型，相比其它活动轮廓模型，CV 模型具有如下几个优点。CV 模型是基于 Mumford-Shah 分割技巧和水平集方法，而不是基于边界函数使得演变曲线停在想要的边缘上。而且即使初始图像含有噪声，也不需要光滑初始图像，边缘的位置仍可以很好地被检测和保留。CV 模型可以检测不是由梯度定义的边缘或者是非常光滑的边缘，而对于这些边缘，经典的活动轮廓模型是不适用的。最后 CV 模型可以仅从一条初始曲线自动地检测内部轮廓，而且初始曲线的位置不必环绕待检测的物体，可以在图像的任意位置。这是 CV 模型一个非常重要的优点。

但是 CV 模型主要对于具有同质区域的图像有较为显著的分割效果，而不可以处理具有不均匀强度的图像。在 CV 模型里，常量 c_1 和 c_2 用来近似区域 $\text{inside}(C)$ 和 $\text{outside}(C)$ 内的图像强度，很显然，如果原始图像的图像强度在 $\text{inside}(C)$ 或者 $\text{outside}(C)$ 内并不是均匀的，这种全局的拟合将会是不准确的。也就是说 CV 模型仅考虑图像强度的全局信息，而不包含图像任何局部强度信息，而图像的局部强度信息对于具有图像强度不均匀性质的图像分割是至关重要的，因此 CV 模型不可以分割具有图像强度不均匀性质的图像。

1.2 数学原理

CV 模型的能量泛函为：

$$\begin{aligned} F^{CV}(c_1, c_2, C) = & \lambda_1 \int_{inside(C)} |u_0(x, y) - c_1|^2 dx dy \\ & + \lambda_2 \int_{outside(C)} |u_0(x, y) - c_2|^2 dx dy \\ & + \nu |C| \end{aligned}$$

其中 $\nu, \lambda_1, \lambda_2$ 为参数, $\nu |C|$ 项为边界长度项, $\lambda_1 \int_{inside(C)} |u_0(x, y) - c_1|^2 dx dy$,

$\lambda_2 \int_{outside(C)} |u_0(x, y) - c_2|^2 dx dy$ 项为数据拟合项。

我们设 ϕ 为一个水平集函数, 使得 $\phi(x, y) = 0$ 为边界 C , $\phi(x, y) > 0$ 为内部, $\phi(x, y) < 0$ 为外部。则 CV 模型的能量泛函可以表示为：

$$\begin{aligned} F^{CV}(c_1, c_2, \phi) = & \lambda_1 \int_{\Omega} |u_0(x, y) - c_1|^2 H(\phi(x, y)) dx dy \\ & + \lambda_2 \int_{\Omega} |u_0(x, y) - c_2|^2 [1 - H(\phi(x, y))] dx dy \\ & + \nu \int_{\Omega} |\nabla H(\phi(x, y))| dx dy \end{aligned}$$

其中 $\nu, \lambda_1, \lambda_2$ 为参数, Ω 为图像区域, H 为 Heaviside 函数。 $\nu \int_{\Omega} |\nabla H(\phi(x, y))| dx dy$ 为边界长度项,

$\lambda_1 \int_{\Omega} |u_0(x, y) - c_1|^2 H(\phi(x, y)) dx dy$, $\lambda_2 \int_{\Omega} |u_0(x, y) - c_2|^2 [1 - H(\phi(x, y))] dx dy$ 项为数据拟合项。为了极小化能量泛函, 我们采用交替极小化的方式, 即轮流优化 c_1, c_2, ϕ 。

在确定一个初始值之后, 我们轮流优化 c_1, c_2, ϕ

首先优化 c_1 :

$$\begin{aligned} & \frac{\partial}{\partial c_1} F^{CV} = 0 \\ \Rightarrow & \frac{\partial}{\partial c_1} \lambda_1 \int_{\Omega} |u_0(x, y) - c_1|^2 H(\phi(x, y)) dx dy = 0 \\ \Rightarrow & \frac{\partial}{\partial c_1} \int_{\Omega} (u_0^2(x, y) - 2c_1 u_0(x, y) + c_1^2) H(\phi(x, y)) dx dy = 0 \\ \Rightarrow & -2 \int_{\Omega} u_0(x, y) H(\phi(x, y)) dx dy + 2c_1 \int_{\Omega} H(\phi(x, y)) dx dy = 0 \\ \Rightarrow & c_1 = \frac{\int_{\Omega} u_0(x, y) H(\phi(x, y)) dx dy}{\int_{\Omega} H(\phi(x, y)) dx dy} \end{aligned}$$

故令:

$$c_1 = \frac{\int_{\Omega} u_0(x, y) H(\phi(x, y)) dx dy}{\int_{\Omega} H(\phi(x, y)) dx dy}$$

然后优化 c_2 :

$$\begin{aligned}
& \frac{\partial}{\partial c_2} F^{CV} = 0 \\
& \Rightarrow \frac{\partial}{\partial c_2} \lambda_2 \int_{\Omega} |u_0(x, y) - c_1|^2 [1 - H(\phi(x, y))] \, dx dy = 0 \\
& \Rightarrow \frac{\partial}{\partial c_2} \int_{\Omega} (u_0^2(x, y) - 2c_2 u_0(x, y) + c_2^2) [1 - H(\phi(x, y))] \, dx dy = 0 \\
& \Rightarrow -2 \int_{\Omega} u_0(x, y) [1 - H(\phi(x, y))] \, dx dy + 2c_2 \int_{\Omega} [1 - H(\phi(x, y))] \, dx dy = 0 \\
& \Rightarrow c_2 = \frac{\int_{\Omega} u_0(x, y) [1 - H(\phi(x, y))] \, dx dy}{\int_{\Omega} [1 - H(\phi(x, y))] \, dx dy}
\end{aligned}$$

故令:

$$c_2 = \frac{\int_{\Omega} u_0(x, y) [1 - H(\phi(x, y))] \, dx dy}{\int_{\Omega} [1 - H(\phi(x, y))] \, dx dy}$$

最后优化 ϕ :

令:

$$\begin{aligned}
f(\mathbf{x}, \phi(\mathbf{x}), \nabla \phi(\mathbf{x})) = & \lambda_1 |u_0(\mathbf{x}) - c_1|^2 H(\phi(\mathbf{x})) \\
& + \lambda_2 |u_0(\mathbf{x}) - c_2|^2 [1 - H(\phi(\mathbf{x}))] \\
& + \nu \delta(\phi(\mathbf{x})) |\nabla \phi(\mathbf{x})|
\end{aligned}$$

则:

$$F^{CV}(\phi) = \int_{\Omega} f(\mathbf{x}, \phi(\mathbf{x}), \nabla \phi(\mathbf{x})) \, d\mathbf{x}$$

故 F^{CV} 在 ϕ 处的梯度:

$$\begin{aligned}
\frac{\delta}{\delta \phi} F^{CV} = & \frac{\partial f}{\partial \phi} - \nabla \cdot \frac{\partial f}{\partial \nabla \phi} \\
= & \lambda_1 |u_0(\mathbf{x}) - c_1|^2 \delta(\phi(\mathbf{x})) \\
& - \lambda_2 |u_0(\mathbf{x}) - c_2|^2 \delta(\phi(\mathbf{x})) \\
& + \nabla \cdot \left(\nu \delta(\phi(\mathbf{x})) \frac{\nabla \phi(\mathbf{x})}{|\nabla \phi(\mathbf{x})|} \right) \\
= & \delta(\phi(\mathbf{x})) \left[\lambda_1 (u_0(\mathbf{x}) - c_1)^2 - \lambda_2 (u_0(\mathbf{x}) - c_2)^2 - \nu \nabla \cdot \left(\frac{\nabla \phi(\mathbf{x})}{|\nabla \phi(\mathbf{x})|} \right) \right]
\end{aligned}$$

然后 ϕ 向负梯度方向更新。

1.3 代码实现

为了用程序实现 CV 模型, 我们定义一个 CV_model 类, 把 c_1, c_2, ϕ 作为其类属性, 然后在其内部定义一个 fit 方法, 用来优化 c_1, c_2, ϕ 。在使用要处理的图像实例化一个 CV_model 类之后, 我们调用 fit 方法之后, 就会不断更新迭代 c_1, c_2, ϕ , 直到达到设置的迭代次数上限。

具体代码实现如下:

```

1 import math
2 import numpy as np
3 from PIL import Image

```

```

4 import matplotlib.pyplot as plt
5 from scipy.io import loadmat
6 from scipy.signal import convolve2d
7
8 epsilon = 0.01
9 sigma = 25
10
11 def set_sigma(a: float):
12     global sigma
13     sigma = a
14 def H_pointwise(x: float) -> float:
15     return (1/2) * (1 + (2/math.pi) * math.atan(x/epsilon))
16
17 H = np.vectorize(H_pointwise)
18
19 def delta_pointwise(x: float) -> float:
20     return (1/math.pi)*(epsilon/(x**2 + epsilon**2))
21
22 def gradient_length(image: np.array) -> float:
23     gradient = np.gradient(image)
24     return np.sqrt(gradient[0]**2 + gradient[1]**2)
25
26 delta = np.vectorize(delta_pointwise)
27
28 def K_pointwise(u: np.array) -> float:
29     return np.exp(-(np.linalg.norm(u)**2)/(2*sigma**2))/(2*math.pi*
        sigma**2)
30
31 K = np.vectorize(K_pointwise)
32
33 def divergence_after_normalized_gradient(image: np.array) -> np.array:
34     gradient = np.gradient(image)
35     magnitude = np.sqrt(gradient[0]**2 + gradient[1]**2)
36     magnitude[magnitude == 0] = 0.01
37     normalized_gradient = gradient / magnitude
38     divergence = np.gradient(normalized_gradient[0])[0] + np.gradient(
        normalized_gradient[1])[1]
39
40     return divergence
41
42 def laplace(image: np.array) -> np.array:

```

```

43     gradient = np.gradient(image)
44     laplacian = np.gradient(gradient[0])[0] + np.gradient(gradient[1])
45         [1]
46     return laplacian
47
48 class CV_model:
49     def __init__(self, figure: np.array, c1: float = 0, c2: float =
50         255, lambda1: float = 1, lambda2: float = 1, nu: float = 1):
51         self.figure = figure
52         self.c1 = c1
53         self.c2 = c2
54         self.phi = np.ones_like(self.figure)
55         self.phi[0, :] = self.phi[-1, :] = self.phi[:, 0] = self.phi
56            [:, -1] = -1
57         self.lambda1 = lambda1
58         self.lambda2 = lambda2
59         self.nu = nu
60
61     def update_phi(self, learning_rate: float):
62         flow = delta(self.phi) * (self.nu *
63             divergence_after_normalized_gradient(self.phi) - self.
64             lambda1 * (self.figure - self.c1)**2 + self.lambda2 * (
65             self.figure - self.c2)**2)
66         self.phi = self.phi + learning_rate * flow
67
68     def update_c1(self, H_phi: np.array):
69         self.c1 = np.sum(self.figure * H_phi) / np.sum(H_phi)
70
71     def update_c2(self, H_phi: np.array):
72         self.c2 = np.sum(self.figure * (1 - H_phi)) / np.sum(1 - H_phi
73             )
74
75     def fit(self, learning_rate: float, max_iter: int = 100):
76
77         for i in range(max_iter):
78             H_phi = H(self.phi)
79             self.update_c1(H_phi)
80             self.update_c2(H_phi)
81             self.update_phi(learning_rate)
82
83     def draw(self, i: int):

```

```

77         colored_figure = np.repeat(self.figure[:, :, np.newaxis], 3,
            axis=2)
78         plt.imshow(colored_figure, cmap='gray')
79         plt.contour(self.phi, [0], colors='r')
80         plt.savefig(fname=f"out/img/output{i+1}_CV.png", bbox_inches="
            tight", pad_inches=0.1)
81         plt.show()
82
83     # 合成图像强度不均匀的图像
84     def generate_synthetic_image() -> np.array:
85         Img = np.zeros((101, 101))
86         for i in range(101):
87             for j in range(101):
88                 Img[i, j] = 30 * (1 + np.sin(0.01 * np.pi * (i - j)))
89         Img[50, 50] = 100
90         for i in range(101):
91             for j in range(101):
92                 if np.sqrt((i - 50) ** 2 + (j - 50) ** 2) <= (35 + 7 * np.
                    cos(8 * np.arctan((j - 50)*(i - 50)))):
93                     Img[i, j] = 100 * (1 + 0.2 * np.sin(0.01 * np.pi * (i
                        - j)))
94         return Img
95
96     def get_img()->list:
97         imgs = []
98         for i in range(1, 6):
99             img = Image.open(f"fig/{i}.bmp")
100             img = np.array(img)
101             imgs.append(img)
102             img = Image.open("fig/6.png")
103             img = np.array(img)
104             img_gray = img[:, :, 0]
105             imgs.append(img_gray)
106             data = loadmat('fig/brain_img75.mat')
107             img = data['img']
108             imgs.append(img)
109             img = Image.open("fig/myBrain_axial.bmp")
110             img = np.array(img)
111             imgs.append(img)
112             img = generate_synthetic_image()/120
113             imgs.append(img)

```


```

114     return imgs
115
116
117
118 if __name__ == '__main__':
119     for i, img in enumerate(imgs):
120         if i != 8:
121             model = CV_model(img, lambda1=1, lambda2=1, nu=1)
122         else:
123             model = CV_model(img, lambda1=256, lambda2=256, nu=1)
124             model.fit(0.1, 500)
125             model.draw(i)

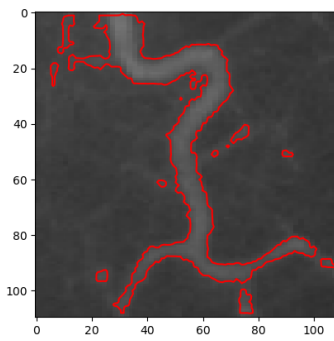
```

1.4 实验结果


CV 模型的实验结果如下：




(1) 原图




(2) CV 模型处理后




(3) 原图




(4) CV 模型处理后




(5) 原图




(6) CV 模型处理后




(7) 原图




(8) CV 模型处理后




(9) 原图




(10) CV 模型处理后




(11) 原图




(12) CV 模型处理后




(13) 原图




(14) CV 模型处理后




(15) 原图



(16) CV 模型处理后



(17) 原图



(18) CV 模型处理后

1.5 结论与讨论

可以看到，对于图像强度均匀的图片的分割，CV 模型具有优良的效果，但是对于图像强度不均匀的图片，比如上面的最后一张图，CV 模型就不能给出令人满意的结果。

2 RSF 模型

2.1 模型介绍

不同于 CV 模型用两个常量 c_1 和 c_2 来近似轮廓线 C 两侧的区域 $\text{inside}(C)$ 和 $\text{outside}(C)$ 内的图像强度。RSF 模型用两个拟合函数 $f_1(x)$ 和 $f_2(x)$ 来拟合 C 两侧的区域内的图像强度。注意到 f_1 和 f_2 的值是随着中心点 x 的变化而变化的。 f_1 和 f_2 的这种空间变化性质使得 RSF 模型从本质上区别于 CV 模型，这种空间变化性质来源于空间变化的核函数 K_σ 的局部化性质。RSF 模型的区域可伸缩性也来源于核函数 K_σ ，尺度参数 σ 可以控制局部区域的大小，从小的邻域到整个定义域，这样就可以在一个可控制尺度的区域内充分利用图像的强度信息用于引导活动轮廓线的移动。RSF 模型通过使用核函数 K_σ ，充分利用图像的局部强度信息，因此该模型可以分割具有图像强度不均匀性质的图像，而且对于一些具有弱边界的物体如血管等的分割有很好的效果。但是 RSF 模型仅仅利用图像的局部信息可能会导致能量泛函的局部极小，因此 RSF 模型的分割结果会更加依赖于轮廓线的初始化。此外，因为 RSF 模型是非凸的，这也是导致局部极小解存在的一个原因。

2.2 数学原理

RSF 模型的能量泛函为：

$$\begin{aligned} F^{RSF}(f_1, f_2, C) = & \lambda_1 \int_{\Omega} \left(\int_{\text{inside}(C)} K(\mathbf{x} - \mathbf{y}) |u_0(\mathbf{y}) - f_1(\mathbf{x})|^2 d\mathbf{y} \right) d\mathbf{x} \\ & + \lambda_2 \int_{\Omega} \left(\int_{\text{outside}(C)} K(\mathbf{x} - \mathbf{y}) |u_0(\mathbf{y}) - f_2(\mathbf{x})|^2 d\mathbf{y} \right) d\mathbf{x} \\ & + \nu |C| \end{aligned}$$

其中 $\nu, \lambda_1, \lambda_2$ 为参数， $\nu|C|$ 项为边界长度项， $\lambda_1 \int_{\Omega} \left(\int_{\text{inside}(C)} K(\mathbf{x} - \mathbf{y}) |u_0(\mathbf{y}) - f_1(\mathbf{x})|^2 d\mathbf{y} \right) d\mathbf{x}$ ， $\lambda_2 \int_{\Omega} \left(\int_{\text{outside}(C)} K(\mathbf{x} - \mathbf{y}) |u_0(\mathbf{y}) - f_2(\mathbf{x})|^2 d\mathbf{y} \right) d\mathbf{x}$ 项为数据拟合项。

我们设 ϕ 为一个水平集函数，使得 $\phi(\mathbf{x}) = 0$ 为边界 C ， $\phi(\mathbf{x}) > 0$ 为内部， $\phi(\mathbf{x}) < 0$ 为外部。则 RSF 模型的能量泛函可以表示为：

$$\begin{aligned} F^{RSF}(f_1, f_2, \phi) = & \mathcal{E}^{RSF}(f_1, f_2, \phi) + \nu \mathcal{L}^{RSF}(\phi) + \mu \mathcal{P}^{RSF}(\phi) \\ = & \lambda_1 \int_{\Omega} \left(\int_{\Omega} K(\mathbf{x} - \mathbf{y}) |u_0(\mathbf{y}) - f_1(\mathbf{x})|^2 H(\phi(\mathbf{y})) d\mathbf{y} \right) d\mathbf{x} \\ & + \lambda_2 \int_{\Omega} \left(\int_{\Omega} K(\mathbf{x} - \mathbf{y}) |u_0(\mathbf{y}) - f_2(\mathbf{x})|^2 [1 - H(\phi(\mathbf{y}))] d\mathbf{y} \right) d\mathbf{x} \\ & + \nu \int_{\Omega} |\nabla H(\phi(\mathbf{x}))| d\mathbf{x} \\ & + \mu \int_{\Omega} \frac{1}{2} (|\nabla \phi(\mathbf{x})| - 1)^2 d\mathbf{x} \end{aligned}$$

其中 $\nu, \lambda_1, \lambda_2, \mu$ 为参数， $\nu \mathcal{L}^{RSF}(\phi)$ 项为边界长度项， $\mathcal{E}^{RSF}(f_1, f_2, \phi)$ 项为数据拟合项， $\mu \mathcal{P}^{RSF}(\phi)$ 为水平集正则项。为了极小化能量泛函，我们采用交替极小化的方式，即轮流优化 f_1, f_2, ϕ 。

在确定一个初始值之后，我们轮流优化 f_1, f_2, ϕ

首先优化 f_1 :

$$\begin{aligned}
& \frac{\delta}{\delta f_1} F^{RSF} = 0 \\
& \Rightarrow \frac{\delta}{\delta f_1} \lambda_1 \int_{\Omega} \left(\int_{\Omega} K(\mathbf{x} - \mathbf{y}) |u_0(\mathbf{y}) - f_1(\mathbf{x})|^2 H(\phi(\mathbf{y})) \, d\mathbf{y} \right) d\mathbf{x} = 0 \\
& \Rightarrow \frac{\delta}{\delta f_1} \int_{\Omega} \left(\int_{\Omega} K(\mathbf{x} - \mathbf{y}) (-2u_0(\mathbf{y})f_1(\mathbf{x}) + f_1^2(\mathbf{x})) H(\phi(\mathbf{y})) \, d\mathbf{y} \right) d\mathbf{x} = 0 \\
& \Rightarrow -2 \int_{\Omega} K(\mathbf{x} - \mathbf{y}) u_0(\mathbf{y}) H(\phi(\mathbf{y})) \, d\mathbf{y} + 2f_1 \int_{\Omega} K(\mathbf{x} - \mathbf{y}) H(\phi(\mathbf{y})) \, d\mathbf{y} = 0 \\
& \Rightarrow f_1 = \frac{\int_{\Omega} K(\mathbf{x} - \mathbf{y}) u_0(\mathbf{y}) H(\phi(\mathbf{y})) \, d\mathbf{y}}{\int_{\Omega} K(\mathbf{x} - \mathbf{y}) H(\phi(\mathbf{y})) \, d\mathbf{y}} \\
& \Rightarrow f_1 = \frac{K(\mathbf{x}) * [u_0(\mathbf{x}) H(\phi(\mathbf{x}))]}{K(\mathbf{x}) * H(\phi(\mathbf{x}))}
\end{aligned}$$

故令:

$$f_1 = \frac{K(\mathbf{x}) * [u_0(\mathbf{x}) H(\phi(\mathbf{x}))]}{K(\mathbf{x}) * H(\phi(\mathbf{x}))}$$

然后优化 f_2 :

$$\begin{aligned}
& \frac{\delta}{\delta f_2} F^{RSF} = 0 \\
& \Rightarrow \frac{\delta}{\delta f_2} \lambda_2 \int_{\Omega} \left(\int_{\Omega} K(\mathbf{x} - \mathbf{y}) |u_0(\mathbf{y}) - f_2(\mathbf{x})|^2 [1 - H(\phi(\mathbf{y}))] \, d\mathbf{y} \right) d\mathbf{x} = 0 \\
& \Rightarrow \frac{\delta}{\delta f_2} \int_{\Omega} \left(\int_{\Omega} K(\mathbf{x} - \mathbf{y}) (-2u_0(\mathbf{y})f_2(\mathbf{x}) + f_2^2(\mathbf{x})) [1 - H(\phi(\mathbf{y}))] \, d\mathbf{y} \right) d\mathbf{x} = 0 \\
& \Rightarrow -2 \int_{\Omega} K(\mathbf{x} - \mathbf{y}) u_0(\mathbf{y}) [1 - H(\phi(\mathbf{y}))] \, d\mathbf{y} + 2f_2 \int_{\Omega} K(\mathbf{x} - \mathbf{y}) [1 - H(\phi(\mathbf{y}))] \, d\mathbf{y} = 0 \\
& \Rightarrow f_2 = \frac{\int_{\Omega} K(\mathbf{x} - \mathbf{y}) u_0(\mathbf{y}) [1 - H(\phi(\mathbf{y}))] \, d\mathbf{y}}{\int_{\Omega} K(\mathbf{x} - \mathbf{y}) [1 - H(\phi(\mathbf{y}))] \, d\mathbf{y}} \\
& \Rightarrow f_2 = \frac{K(\mathbf{x}) * [u_0(\mathbf{x}) [1 - H(\phi(\mathbf{x}))]]}{K(\mathbf{x}) * [1 - H(\phi(\mathbf{x}))]}
\end{aligned}$$

故令:

$$f_2 = \frac{K(\mathbf{x}) * [u_0(\mathbf{x}) [1 - H(\phi(\mathbf{x}))]]}{K(\mathbf{x}) * [1 - H(\phi(\mathbf{x}))]}$$

最后优化 ϕ :

令:

$$\begin{aligned}
f(\mathbf{x}, \phi(\mathbf{x}), \nabla \phi(\mathbf{x})) = & \lambda_1 \int_{\Omega} K(\mathbf{x} - \mathbf{y}) |u_0(\mathbf{y}) - f_1(\mathbf{x})|^2 H(\phi(\mathbf{y})) \, d\mathbf{y} \\
& + \lambda_2 \int_{\Omega} K(\mathbf{x} - \mathbf{y}) |u_0(\mathbf{y}) - f_2(\mathbf{x})|^2 [1 - H(\phi(\mathbf{y}))] \, d\mathbf{y} \\
& + \nu \delta(\phi(\mathbf{x})) |\nabla \phi(\mathbf{x})| \\
& + \mu \frac{1}{2} (|\nabla \phi(\mathbf{x})| - 1)^2
\end{aligned}$$

则:

$$F^{RSF}(\phi) = \int_{\Omega} f(\mathbf{x}, \phi(\mathbf{x}), \nabla \phi(\mathbf{x})) \, d\mathbf{x}$$

记:

$$e_1(\mathbf{x}) = \int_{\Omega} K(\mathbf{y} - \mathbf{x}) (u_0(\mathbf{x}) - f_1(\mathbf{y}))^2 d\mathbf{y}$$

$$e_2(\mathbf{x}) = \int_{\Omega} K(\mathbf{y} - \mathbf{x}) (u_0(\mathbf{x}) - f_2(\mathbf{y}))^2 d\mathbf{y}$$

则 F^{RSF} 在 ϕ 处的梯度:

$$\begin{aligned} \frac{\delta}{\delta\phi} F^{RSF} &= \frac{\partial f}{\partial\phi} - \nabla \cdot \frac{\partial f}{\partial\nabla\phi} \\ &= \lambda_1 \int_{\Omega} K(\mathbf{y} - \mathbf{x}) (u_0(\mathbf{x}) - f_1(\mathbf{y}))^2 d\mathbf{y} \delta(\phi(\mathbf{x})) \\ &\quad - \lambda_2 \int_{\Omega} K(\mathbf{y} - \mathbf{x}) (u_0(\mathbf{x}) - f_2(\mathbf{y}))^2 d\mathbf{y} \delta(\phi(\mathbf{x})) \\ &\quad + \nu \nabla \cdot \left(\delta(\phi(\mathbf{x})) \frac{\nabla\phi(\mathbf{x})}{|\nabla\phi(\mathbf{x})|} \right) \\ &\quad + \mu \nabla \cdot \left(\nabla\phi(\mathbf{x}) - \frac{\nabla\phi(\mathbf{x})}{|\nabla\phi(\mathbf{x})|} \right) \\ &= \delta(\phi(\mathbf{x})) \left[\lambda_1 e_1(\mathbf{x}) - \lambda_2 e_2(\mathbf{x}) - \nu \nabla \cdot \left(\frac{\nabla\phi(\mathbf{x})}{|\nabla\phi(\mathbf{x})|} \right) \right] - \mu \left(\nabla^2\phi(\mathbf{x}) - \nabla \cdot \left(\frac{\nabla\phi(\mathbf{x})}{|\nabla\phi(\mathbf{x})|} \right) \right) \end{aligned}$$

然后令 ϕ 向负梯度方向更新。

2.3 代码实现

实现思路与 CV 模型相似，我们定义一个 RSF_model 类，把 f_1, f_2, ϕ 作为其类属性，然后在其内部定义一个 fit 方法，用来优化 f_1, f_2, ϕ 。在使用要处理的图像实例化一个 RSF_model 类之后，我们调用 fit 方法之后，就会不断更新迭代 f_1, f_2, ϕ ，直到达到设置的迭代次数上限。具体代码实现如下：

```

1 import math
2 import numpy as np
3 from PIL import Image
4 import matplotlib.pyplot as plt
5 from scipy.io import loadmat
6 from scipy.signal import convolve2d
7
8 epsilon = 0.01
9 sigma = 25
10
11 def set_sigma(a: float):
12     global sigma
13     sigma = a
14 def H_pointwise(x: float) -> float:
15     return (1/2) * (1 + (2/math.pi) * math.atan(x/epsilon))
16
17 H = np.vectorize(H_pointwise)
18

```

```

19 def delta_pointwise(x: float) -> float:
20     return (1/math.pi)*(epsilon/(x**2 + epsilon**2))
21
22 def gradient_length(image: np.array) -> float:
23     gradient = np.gradient(image)
24     return np.sqrt(gradient[0]**2 + gradient[1]**2)
25
26 delta = np.vectorize(delta_pointwise)
27
28 def K_pointwise(u: np.array) -> float:
29     return np.exp(-(np.linalg.norm(u)**2)/(2*sigma**2))/(2*math.pi*
        sigma**2)
30
31 K = np.vectorize(K_pointwise)
32
33
34 def divergence_after_normalized_gradient(image: np.array) -> np.array:
35     gradient = np.gradient(image)
36     magnitude = np.sqrt(gradient[0]**2 + gradient[1]**2)
37     magnitude[magnitude == 0] = 0.01
38     normalized_gradient = gradient / magnitude
39     divergence = np.gradient(normalized_gradient[0])[0] + np.gradient(
        normalized_gradient[1])[1]
40     return divergence
41
42 def laplace(image: np.array) -> np.array:
43     gradient = np.gradient(image)
44     laplacian = np.gradient(gradient[0])[0] + np.gradient(gradient[1])
        [1]
45     return laplacian
46
47 class RSF_model:
48     def __init__(self, figure: np.array, lambda1: float = 1, lambda2:
        float = 1, nu: float = 1, mu: float = 1, left: int = 10, right
        : int = 10, up: int = 10, down: int = 10, difference: int = 8,
        mode: bool = False, sigma: float = 25):
49         set_sigma(sigma)
50         self.figure = figure
51         self.f1 = np.zeros_like(self.figure)
52         self.f2 = np.ones_like(self.figure)
53         if mode:

```

```

54         self.phi = np.ones_like(self.figure)
55     else:
56         self.phi = np.zeros_like(self.figure)
57     self.phi[:up, :] = self.phi[-down:, :] = self.phi[:, :left] =
        self.phi[:, -right:] = difference
58     self.lambda1 = lambda1
59     self.lambda2 = lambda2
60     self.nu = nu
61     self.mu = mu
62     self.omega = np.empty(self.figure.shape, dtype=object)
63     for index, _ in np.ndenumerate(self.omega):
64         self.omega[index] = index
65     self.K_omega = K(self.omega)
66
67     def K_omega_mines_index(self, index: tuple) -> np.array:
68         i, j = index
69         m, n = self.omega.shape
70         K_00 = np.fliplr(np.flipud(self.K_omega[:i + 1, :j + 1]))
71         K_01 = np.flipud(self.K_omega[:i + 1, 1: n - j])
72         K_10 = np.fliplr(self.K_omega[1:m - i, :j + 1])
73         K_11 = self.K_omega[1:m - i, 1:n - j]
74         Komega_minus_index = np.concatenate([np.concatenate([K_00,
75             K_01], axis=1), np.concatenate([K_10, K_11], axis=1)],
76             axis=0)
77         return Komega_minus_index
78
79     def e1_e2_pointwise(self, index: tuple) -> tuple:
80         i, j = index
81         K_y_minus_index = self.K_omega_mines_index(index)
82         return np.sum((K_y_minus_index)*((self.figure[i, j] - self.f1)
83             **2)), np.sum((K_y_minus_index)*((self.figure[i, j] - self
84             .f2)**2))
85
86     def update_phi(self, learning_rate: float):
87         compute_e1_e2 = np.vectorize(self.e1_e2_pointwise)
88         e1, e2 = compute_e1_e2(self.omega)
89         div = divergence_after_normalized_gradient(self.phi)
90         delta_phi = delta(self.phi)
91         flow = -delta_phi * (self.lambda1 * e1 - self.lambda2 * e2) +

```

```

        self.nu * delta_phi * div + self.mu * (laplace(self.phi) -
        div)

90
91     self.phi = self.phi + learning_rate * flow
92
93     def update_f1(self, H_phi: np.array):
94         denominator = convolve2d(self.K_omega, H_phi, mode='same')
95         denominator[denominator == 0] = 0.001
96         self.f1 = convolve2d(self.K_omega, H_phi*self.figure, mode='
            same') / denominator
97
98     def update_f2(self, H_phi: np.array):
99         denominator = convolve2d(self.K_omega, 1-H_phi, mode='same')
100        denominator[denominator == 0] = 0.001
101        self.f2 = convolve2d(self.K_omega, (1-H_phi)*self.figure, mode
            ='same') / denominator
102
103    def fit(self, learning_rate: float, max_iter: int = 100):
104        for i in range(max_iter):
105            H_phi = H(self.phi)
106            self.update_f1(H_phi)
107            self.update_f2(H_phi)
108            self.update_phi(learning_rate)
109            print(i)
110
111    def draw(self, i: int):
112        colored_figure = np.repeat(self.figure[:, :, np.newaxis], 3,
            axis=2)
113        plt.imshow(colored_figure, cmap='gray')
114        plt.contour(self.phi, [0], colors='r')
115        plt.savefig(fname=f"out/img/output{i+1}_RSF.png", bbox_inches=
            "tight", pad_inches=0.1)
116        plt.show()
117
118
119    # 合成图像强度不均匀的图像
120    def generate_synthetic_image() -> np.array:
121        Img = np.zeros((101, 101))
122        for i in range(101):
123            for j in range(101):
124                Img[i, j] = 30 * (1 + np.sin(0.01 * np.pi * (i - j)))

```

```

125
126     Img[50, 50] = 100
127
128     for i in range(101):
129         for j in range(101):
130             if np.sqrt((i - 50) ** 2 + (j - 50) ** 2) <= (35 + 7 * np.
131                 cos(8 * np.arctan((j - 50)*(i - 50)))):
132                 Img[i, j] = 100 * (1 + 0.2 * np.sin(0.01 * np.pi * (i
133                     - j)))
134
135     return Img
136
137 def get_img()->list:
138     imgs = []
139     for i in range(1, 6):
140         img = Image.open(f"fig/{i}.bmp")
141         img = np.array(img)
142         imgs.append(img)
143     img = Image.open("fig/6.png")
144     img = np.array(img)
145     img_gray = img[:, :, 0]
146     imgs.append(img_gray)
147     data = loadmat('fig/brain_img75.mat')
148     img = data['img']
149     imgs.append(img)
150     img = Image.open("fig/myBrain_axial.bmp")
151     img = np.array(img)
152     imgs.append(img)
153     img = generate_synthetic_image()/120
154     imgs.append(img)
155     return imgs
156
157 if __name__ == '__main__':
158     imgs = get_img()
159     max_iter_list_RSF = [30, 30, 6, 100, 30, 30, 1, 1, 1]
160     left_list = [10, 1, 5, 10, 1, 10, 10, 10, 5]
161     right_list = [1, 1, 20, 4, 1, 8, 10, 5, 5]
162     up_list = [1, 1, 8, 5, 1, 5, 10, 10, 5]
163     down_list = [1, 1, 10, 10, 1, 10, 10, 5, 7]
164     sigma_list = [75, 25, 25, 25, 25, 20, 25, 25, 25]
165     learning_rate_list = [.1, .1, .1, .2, .1, .1, .1, .1, .1]

```




```

164 difference_list = [255, 255, 8, 255, 255, 8, 8, 8, 8]
165 nu_list = [.5, .5, 1, 100, 1, 5, 1, 1, 1]
166 mu_list = [.5, .5, 1, 0, .5, .1, 1, 1, 1]
167 mode_list = [True, True, False, True, True, True, False, False,
               False]
168
169
170 for i in range(9):
171     img = imgs[i]
172     model = RSF_model(img, lambda1=1, lambda2=1, nu=nu_list[i],
                        mu=mu_list[i], left=left_list[i], right=right_list[i], up
                        =up_list[i], down=down_list[i], difference=
                        difference_list[i], mode=mode_list[i], sigma=sigma_list[i]
                        ])
173     model.fit(learning_rate_list[i], max_iter_list_RSF[i])
174     model.draw(i)


```

2.4 实验结果


RSF 模型的实验结果如下：




(19) 原图




(20) RSF 模型处理后




(21) 原图




(22) RSF 模型处理后




(23) 原图




(24) RSF 模型处理后




(25) 原图




(26) RSF 模型处理后



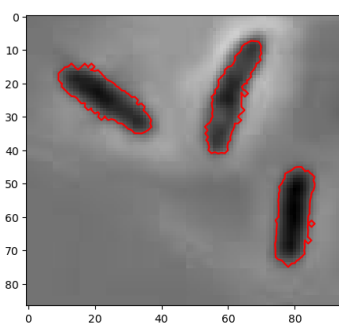
(27) 原图




(28) RSF 模型处理后




(29) 原图




(30) RSF 模型处理后




(31) 原图




(32) RSF 模型处理后




(33) 原图



(34) RSF 模型处理后



(35) 原图



(36) RSF 模型处理后

2.5 结论与讨论

可以看到，对于图像强度不均匀的情况，RSF 模型的效果优于 CV 模型，比如最后一张图，RSF 就把图里的圆完美地分出来了，但可能是因为初始值和超参数的选取不是很恰当，有些图像的分割效果不是很理想。